



Université de Thiès
unité de formation et de recherche
en
sciences économiques et sociales
département management des organisations
Master 1 sciences des données et applications

Projet technique de sondage

Professeurs: Mme. Sall

présenté par:

Nogaye Fall

*Ndèye Penda
Diagne*

Khoudia Mbodji

année académique:

2019

2020

Exercice 1:

Probabilité d'inclusion. Soit la population $\{1, 2, 3\}$ et le plan de sondage suivant

$$P(\{1, 2\}) = 1/2$$

$$P(\{1, 3\}) = 1/4$$

$$P(\{2, 3\}) = 1/4$$

1) Ce n'est pas un sondage aléatoire simple car tous les échantillons de taille $n = 2$ ne sont pas tirés à des probabilités égales

2) Calculons π_1, π_2 et π_3 les probabilités d'inclusion d'ordre 1

$$\pi_1 = 1/2 + 1/4 = 3/4$$

$$\pi_2 = 1/2 + 1/4 = 3/4$$

$$\pi_3 = 1/4 + 1/4 = 1/2$$

3) Calculons π_{12} et π_{23} les probabilités d'inclusions d'ordre 2

$$\pi_{12} = 1/2$$

$$\pi_{23} = 1/4.$$

4) Quel est le π -estimateur de \bar{y} :

a) si l'échantillon $\{1, 2\}$ est tiré

$$Y_1 = 1/N (Y_1/\pi_1) + (Y_2/\pi_2) = 4/9(Y_1 + Y_2)$$

b) si l'échantillon $\{1, 3\}$ est tiré

$$Y_2 = 1/N (Y_1/\pi_1) + (Y_3/\pi_3) = 1/9(4Y_1 + 6Y_3)$$

c) si l'échantillon $\{2, 3\}$ est tiré

$$Y_3 = 1/N (Y_2/\pi_2) + (Y_3/\pi_3) = 1/9(4Y_2 + 6Y_3)$$

5) le π -estimateur est un estimateur sans biais

6) Écrivons ce que seraient les probabilités d'échantillon P et les probabilités d'inclusions π pour un sondage aléatoire simple à probabilités égales sans remise

Si on a un sondage aléatoire simple à probabilités égales sans remise, on a alors pour chaque échantillon la même probabilité d'échantillon et d'inclusion, c'est-à-dire :

$$\pi_{12} = \pi_{13} = \pi_{23} = 1/3.$$

Et

$$\pi_1 = \pi_2 = \pi_3 = 2/3.$$

Exercice 2:

1) la taille de l'échantillon

$$\text{Intervalle de confiance} = \left[f - \frac{1}{\sqrt{n}} ; f + \frac{1}{\sqrt{n}} \right]$$

$$\text{Amplitude de l'intervalle de confiance: } \frac{2}{\sqrt{n}}$$

$$\frac{2}{\sqrt{n}} \leq 0.02$$

$$\frac{\sqrt{n}}{2} \geq \frac{1}{0.02}$$

$$\sqrt{n} \geq \frac{2}{0.02}$$

$$\sqrt{n} \geq 100$$

$$n \geq 100^2$$

$$n \geq 10000$$

La taille de l'échantillon est de 10000.

2) La proportion d'hommes

$$P = \frac{n}{N}$$

$$P = \frac{1500}{10000} = 0.15\%$$

Exercice 3:

- 1) Donnez une estimation du total des notes au test sur le district

$$\hat{T}_{\text{notes}} = n_i * y_i$$

$$T_1 = 40 * 2 = 480$$

$$T_2 = 20 * 8 = 160$$

$$T_3 = 10 * 60 = 600$$

$$T_4 = 40 * 12 = 480$$

$$T_5 = 48 * 11 = 528$$

$$\hat{T}_{\text{moy}} = \frac{N}{n} \sum T_i = \frac{50}{n} (480 + 160 + 600 + 480 + 528) = 22480$$

$$\hat{T}_{\text{moy}} = 22480$$

- 2) Estimons le nombre d'élèves en 6^{eme} du district

$$\hat{N}_{\text{élèves}} = \frac{N}{n} \sum y_i = \frac{50}{n} (40 + 20 + 60 + 40 + 48) = 2080$$

$$\hat{N}_{\text{élèves}} = 2080$$

- 3) Donner une estimation de la moyenne pour n=2000

$$\bar{Y} = \frac{1}{2000} \hat{T} = \frac{22480}{2000} = 11.24$$

$$\bar{Y} = 11.24$$

Comparons le avec

$$\hat{y} = \frac{10}{50} (12 + 8 + 10 + 12 + 11) = 10.6$$

$$= 10.6$$

- 4) Calculons la variance de l'estimateur total

Calculons une estimation de cette variance

$$\hat{V}(\hat{T}) = M^2(1-f) \frac{S_1^2}{m} + \frac{M}{m} \sum N_i^2 (1-f_{2i}) \frac{S_{1i}^2}{n_i}$$

$$\hat{V}(\hat{T}) = M^2(1-f) \frac{S_1^2}{m} + \frac{M}{m} \sum V_i$$

$$S_1^2 = \frac{1}{m-1} \sum \left(\hat{T}_i - \frac{\hat{T}}{M} \right)^2$$

$$S_1^2 = \frac{1}{4} [(480 - 449.6)^2 + (160 - 449.6)^2 + (600 - 449.6)^2 + (480 - 449.6)^2 + (528 - 449.6)^2]$$

$$S_1^2 = 28620.8$$

$$M^2(1-f_i) \frac{S_1^2}{m} = 50^2(1-0.1) * \frac{28620.8}{5} = 1279360$$

$$V_i = N_i^2 (1-f_{2,i}) \frac{S_{1i}^2}{n_i}$$

$$V_1 = 40^2(1-0.25) * \frac{1.5}{10} = 180$$

$$V_2=20^2(1-0.5)*\frac{1.2}{10}=24$$

$$V_3=60^2(1-0.15)*\frac{1.6}{10}=480$$

$$V_4=40^2(1-0.25)*\frac{1.3}{10}=156$$

$$V_5=48^2(1-0.2)*\frac{2}{10}=364.8$$

$$\frac{M}{m} \sum V_i = \frac{50}{5} (180+24+480+156+364.8) = 12048$$

$$\hat{V}(\hat{T}) = 1279360 + 12048 = 12891408$$

En déduire la variance de la moyenne

$$\text{Var}(\hat{y}) = \frac{1}{N^2} \hat{V}(\hat{T}) = \frac{12891408}{2000^2} = 3.22$$

$$\text{Var}(\hat{y}) = 3.221$$

Intervalle de confiance à 95% de la moyenne

$$H / \sqrt{\text{Var}(\hat{y})} = z_{1-\alpha/2} \Rightarrow H = z_{1-\alpha/2} * \sqrt{\text{Var}(\hat{y})}$$

$$z_{1-\alpha/2} = 1.96 \Rightarrow H = 1.96 * \sqrt{3.22} = 3.5$$

$$\hat{y} - z_{1-\alpha/2} * \sqrt{\text{Var}(\hat{y})} = 11.24 - 3.5 = 7.74$$

$$\hat{y} + z_{1-\alpha/2} * \sqrt{\text{Var}(\hat{y})} = 11.24 + 3.5 = 14.74$$

Intervalle de confiance à 95% : [7.74, 14.74]

5) Comparons avec un SAS à probabilités égales

$$f = 50/2000 = 0.25$$

$$\text{Variance} = \text{Var}_{\text{inter}} + \text{Var}_{\text{intra}}$$

$$\text{Var}_{\text{inter}} = \frac{1}{n} \sum_{k=1}^H N_h (\mu_k - \mu)^2$$

$$\text{Var}_{\text{inter}} = \frac{1}{50} (10*12^2 + 10*8^2 + 10*10^2 + 10*12^2 + 10*11^2) - 10.6^2$$

$$\text{Var}_{\text{inter}} = 2.24$$

$$\text{Var}_{\text{intra}} = \frac{1}{n} \sum N_h \sigma_h^2$$

$$\sigma^2 = \frac{N-1}{N} S^2$$

$$\text{Var}_{\text{intra}} = \frac{1}{n} \sum N_h \frac{N-1}{N} S^2$$

$$\text{Var}_{\text{intra}} = \frac{1}{50} * 10 * \frac{9}{10} (1.5 + 1.2 + 1.6 + 1.3 + 2)$$

$$\text{Var}_{\text{intra}} = 1.368$$

$$\text{Variance} = 2.24 + 1.368 = 3.608$$

$$S^2 = \frac{50}{49} * 3.608 = 3.68$$

$$V\hat{ar}(\hat{y})=(1-f)\frac{S^2}{n}=(1-0.25)\frac{3.68}{50}$$

$$V\hat{ar}(\hat{y})=0.07$$

$$H=1.96*\sqrt{0.07}=0.52$$

$$\hat{y}=[10.16, 11.03]$$

La précision est plus nette avec la SAS

a-Donnons une estimation ensembliste de la consommation moyenne de ce type de vehicule au seuil de 5%

$$1.96*\frac{0.8}{\sqrt{25}}=0.314$$

$$\hat{y}=[8.186, 8.8136]$$

b- quel devrait etre le le nombre minimal d'observation au quel on devrait proceder pour conaitre la consommation moyenne a plus ou moin 2dl pres au seuil de 5% et de 1%

- 5% :

$$y \pm \frac{\sigma}{\sqrt{n}}$$

$$\frac{\sigma}{\sqrt{n}}*1.96=0.2$$

$$\frac{\sigma}{\sqrt{n}}=\frac{0.2}{1.96}$$

$$\sqrt{n}=8$$

$$n = 64$$

- 1% :

$$y \pm \frac{\sigma}{\sqrt{n}}$$

$$\frac{\sigma}{\sqrt{n}}*1.96=0.2$$

$$\frac{\sigma}{\sqrt{n}}=\frac{0.2}{1.96}$$

$$\sqrt{n}=8$$

$$n = 64$$

EXERCICE 4:

1)le nombre maximum d'erreurs qu'on peut acceptation dans cette échantillon sans remettre en cause le niveau d'acceptation

$$NE=0,05*200= 10 \text{ erreurs}$$

MEME QUESTIONS AVEC n=400, n=600 et n=1000

*POUR n=400

$$NE=0,05*400= 20 \text{ erreurs}$$

*POUR $n=600$

$$NE=0,05*600= 30 \text{ erreurs}$$

*POUR $n=1000$

$$NE= 0,05*1000= 50 \text{ erreurs}$$

2)le nombre d'enregistrement supplémentaire qu'on doit effectuer pour que l'hypothèse soit acceptée

$$0,05 * x = (7+4) \Rightarrow x=(7+4)/0,05=180 \text{ enregistrements}$$

$X=180$ Donc on doit faire 180 enregistrements supplémentaires pour que l'hypothèse d'un niveau d'acceptation de 5% puisse être raisonnablement retenue.

Exercice 5 :

Un intervalle de confiance de niveau 0.90 est donné par

$$V(\hat{\mu}) = 0.055$$

$$\hat{\mu} = 29.81$$

Intervalle de Confiance : 0.90 = [29.43; 30.19].

2)effectif des échantillons dans chaque strate

a-pour une allocation proportionnelle :

$$\frac{n_h}{n} = \frac{N_h}{N} \Rightarrow n_h = n * \frac{N_h}{N}$$

$$n_1=300*\frac{500}{1060}=141.50=142$$

$$n_2=300*\frac{300}{1060}=84.90=85$$

$$n_3 = 300 * \frac{150}{1060} = 42.45 = 42$$

$$n_4 = 300 * \frac{10}{1060} = 2.83 = 3$$

b-pour une allocation optimale avec $n_h \leq N_h$

$$n_h = \frac{N_h * S_h}{\sum_{k=1}^H N_h S_h}$$

Calculons $\sum_{k=1}^H N_h S_h$:

$$\sum_{k=1}^H N_h S_h = (\sqrt{1.5} * 500) + (\sqrt{4} * 300) + (150 * \sqrt{8}) + (\sqrt{100} * 100) + (\sqrt{10} * 2500) = 3136.64$$

$$n_1 = 300 * \frac{500 * \sqrt{1.5}}{3136.64} = 58.57 = 59$$

$$n_2 = 300 * \frac{300 * \sqrt{4}}{3136.64} = 57.38 = 57$$

$$n_3 = 300 * \frac{150 * \sqrt{8}}{3136.64} = 40.57 = 40$$

$$n_4 = 300 * \frac{100 * \sqrt{100}}{3136.64} = 95.64 = 96$$

$$n_5 = 300 * \frac{10 * \sqrt{2500}}{3136.64} = 47.64 = 48$$

on constate que $n_5 > N_5$ donc on choisit les 10 personnes dans la strate 5

n devient $300 - 10 = 290$

$$n_1 = 290 * \frac{500 * \sqrt{1.5}}{2636.64} = 67.35 = 67$$

$$n_2 = 290 * \frac{300 * \sqrt{4}}{2636.64} = 65.99 = 66$$

$$n_3 = 290 * \frac{150 * \sqrt{8}}{2636.64} = 46.66 = 47$$

$$n_4 = 290 * \frac{100 * \sqrt{10}}{2636.64} = 109.9 = 110$$

on que $n_4 > N_4$ donc les 100 personnes dans l'échantillon 4

n devient : $290 - 100 = 190$

$$n_1 = 190 * \frac{500 * \sqrt{1.5}}{1636.64} = 71.09 = 71$$

$$n_2 = 190 * \frac{300 * \sqrt{4}}{1636.64} = 70.65 = 70$$

$$n_3 = 190 * \frac{150 * \sqrt{8}}{1636.64} = 49.26 = 49$$

donc $n_1 = 71$, $n_2 = 70$, $n_3 = 49$, $n_4 = 100$, $n_5 = 10$

3)

$$V(\hat{t}) = \frac{1}{n} \left(1 - \frac{n}{N}\right) \frac{1}{N} \sum_{k=1}^H N_h S_h^2$$

-Pour l'allocation proportionnelle on obtient

$$V(\hat{\mu}) = 0.0819$$

-Pour l'allocation optimale on obtient

$$V(\hat{\mu}) = 0.00974$$